

# 트랜스포머 네트워크 접근 방식을 이용한 먹이생물의 품질 예측

Nguyen Trong Nghia<sup>1</sup>, Thai Thi Ngoc Hong<sup>1,2</sup>, and Nhu-Tai Do<sup>1</sup>

<sup>1</sup> Department of Artificial Intelligence Convergence, Chonnam National University, 77 Yongbong-ro, Gwangju 500-757, Korea; trongnghia7171@gmail.com (T.-N.N.); donhutai@gmail.com (N.-T.D.)

<sup>2</sup> Department of Economics, Chonnam National University, 77 Yongbong-ro, Gwangju 500-757, Korea; ngochong131297@gmail.com (T.N.-H.T.)

**개요** - 자동화 및 지능화의 맥락에서 최근 몇 년 동안 딥 러닝 및 머신 러닝 기술이 양식업에 널리 적용되어 양식업의 디지털 실현을 위한 새로운 기회를 제공했습니다. 본 연구에서 저희는 스마트 수산양식에 머신러닝 알고리즘과 딥러닝 기술을 적용하여 수질의 4가지 주요 지표를 통해 먹이생물의 세포 수를 기반으로 수질을 예측했습니다. 또한 수산양식에 딥러닝을 적용하는 방법이 설명되었고 얻은 결과가 분석되었습니다. 내부 데이터에 대한 테스트는 양식에 인공 지능을 적용하는 데 매우 유망한 결과를 보여주었으며 이는 비용과 시간을 줄이고 양식 과정의 효율성을 높이는 데 도움이 되었습니다.

**검색어 포함 목록** - 수산양식업, 인공 지능, 딥 러닝, 머신 러닝, 트랜스포머

## 1 소개

수산양식업은 사람의 음식 등을 위해 수중 유기체의 양식(기양, 사육 및 수확)로 정의됩니다. 이는 미래의 식량 공급 문제에 대처하는 것이 점점 더 중요해지는 중요한 산업입니다. [1]에 따르면, 이 산업은 지난 40년 동안 동물성 식품 생산 분야의 다른 부문보다 빠른 속도로 연간 평균 7%의 속도로 성장하고 있습니다. 이러한 발전은 유엔 식량 농업 기구에 따르면 연간 3천만 톤으로 추산되는 세계 인구의 증가하

는 어류 수요에 비례합니다. 이러한 증가하는 용량 및 생산성 요구 사항으로 인해 전통적인 양식 방법은 시간이 지남에 따라 다양한 요인으로 인해 단점을 보일 것입니다. 양식업 영양, 적절한 사료 준비 및 사료 관리에 대한 지식 부족은 사료 축적으로 인해 육지 양식장과 연안 양식장 모두에서 바람직하지 않은 수질을 초래할 것입니다. 예를 들어, 양식 환경에서 박테리아의 불균형으로 이어지는 열악한 수질 관리는 어류 질병 저항성에 영향을 미칠 수 있습니다. 또한, 실험실의 플레이트 수를 기반으로 하는 병원체의 느린 식별과 그에 따른 부적절한 약물 사용으로 인해 부실질병 관리는 어류 조직에 약물/화학물질 잔류물로 이어질 것입니다. 이러한 문제는 수산물의 비효율적인 품질 관리로 이어질 뿐만 아니라 소비자의 건강에도 영향을 미치고 이와 관련된 경제적 손실을 초래합니다. 따라서 이 분야에 인공지능을 적용하기 위한 요구사항이 매우 필요합니다.

딥 러닝/머신 러닝을 양식업에 적용한다는 아이디어는 최근 몇 년 동안 새롭지 않았습니다. 이 분야에서 인공지능의 응용은 어류 바이오매스 검출, 어류의 식별 및 분류, 행동 분석, 수질 매개변수 예측에 관한 연구에 수행되었습니다. 2016년에 Lorenzen et al[2]은 어업 양식업의 기계 학습이 지능형 양식업을 위한 새로운 기회를 제공한다는 어류 생산 보호 전략을 제

안했습니다. 따라서 그들의 연구는 머신 비전과 머신 러닝의 조합이 물고기의 크기, 무게, 수 및 기타 생물학적 정보를 보다 정확하게 추정할 수 있음을 보여주었습니다. 한편, Monkman et al. [3]은 유럽 베이스의 길이 추정을 위해 서로 다른 아키텍처에서 R-CNN 모델을 제공하고 정확도를 측정하고 개선하기 위해 OpenCV를 적용했습니다. 무게 추정 문제에서 연구자들은 주로 물고기의 체형 특성을 기반으로 예측을 하고 컴퓨터 비전 기법을 적용하여 물고기의 크기, 물고기의 모양, 물고기의 등 크기, 면적을 추출하여 품질을 평가했습니다. Fernandes et al. [4]는 선형회귀와 CNN의 융합을 적용하여 물고기의 몸체 경로를 나누어 무게를 추정하는 모델을 개발하여 높은 예측 성능을 얻을 수 있었습니다. 행동 분석은 물고기 행동을 추정하는 작업으로 어류의 복지, 어업 및 생태계를 평가하는 데 도움이 됩니다[5]. 물고기 섭식행동, 집단행동, 비정상행동 등에 대한 많은 연구가 이루어지고 있습니다. 환경의 수질은 수질 지수로 나타냅니다. 따라서 양식 환경의 수질 매개변수에 대한 실시간 모니터링은 가축 생산의 생물학적 이상을 식별하고 질병을 예방하고 관련 위험을 줄이는 데 중요합니다[6]. 이 분야에서 Zhang et al. [7]은 처리 시계열을 활용하기 위해 RNN을 적용하고 용존 산소(DO) 예측 작업을 위한 용존 산소 모니터링 시스템에 사용했습니다. 혁신의 다른 측면에서 Huan et al. [8] 수질 정보와 날씨 정보를 결합하고 GBDT 방법을 적용하여 용존 산소에 더 큰 영향을 미치는 요인을 선택하고 LSTM 모델을 통해 DO를 예측했습니다.

제안된 방법은 양식업, 특히 수질 분석에서 많은 문제를 해결했지만 수질 예측에 기반한 먹이생물은 많은 관심을 받지 못했습니다. 양식산업에서 인공부화기술의 발전은 매우 중요

하며, 이에 따라 인공 종자 사료 유기체의 계획된 대량 재배/관리/섭이 최적화에 대한 관심이 필요합니다. 따라서 본 연구의 주요 목적은 머신러닝과 트랜스포머 네트워크를 적용한 기본 양식 매개변수를 기반으로 수질 분석 및 예측 방법을 제안하는 것입니다.이 문제를 해결함으로써 양식에서 사료 흐름의 제어를 용이하게 할 수 있을 것으로 기대합니다.

이 논문의 나머지 부분은 다음과 같습니다. 먼저 섹션 II에서 자료와 방법에 대한 설명하고 그 다음에는 섹션 II-C에서 실험 결과를 제시할 겁니다. 마지막으로 연구의 몇 가지 향후 과제를 마무리하고 제안할 겁니다.

## II. 자료 및 방법

### 가. 데이터 세트 및 과제

과학기술정보통신부와 인공지능정보사회진흥원의 2021년 인공지능 학습용 데이터구축 지원사업과 관련하여 전국 대학생 또는 취업준비생을 대상으로 2021 수산양식 인공지능 모델 경진대회에 제공된 데이터 세트에 대한 연구를 수행했습니다. 안정적 먹이생물 배양/급이 관리를 통한 인공종사양식 산업의 중요성을 업시키는 동기로 이는 수산양식 먹이생물(플랑크톤)의 감소, 먹이생물의 대량 양식/급이 관리의 어려움, 종자 생산 과정에서의 대량 폐사 등 양식 인공 종자 생산 산업에서 심각한 경제적 손실을 초래하는 몇 가지 문제를 해결하는 것을 목표로 하는 대회입니다.대회에서 저희는 스스로 문제를 정의하고 제공된 데이터(자유주제) 내에서 솔루션을 제안할 수 있습니다.

이 대회에서 얻은 데이터는 두 가지 유형의 데이터가 있습니다. 센서 데이터에는 21일 동




Fig. 1: Aquaculture dataset: microscopy samples on each area.




Fig. 2: Correlation matrix of two areas.

안 고성 및 일해 두 곳의 용존 산소(DO), pH, 염도, 탁도(NTU)에 대한 정보가 포함되어 있고 이미지 데이터는 현미경(그림 1)입니다. 용존 산소(DO)는 어류, 무척추동물 및 수중의 모든 생물이 접근할 수 있는 수생 환경의 산소량입니다. 물 속의 DO는 공기의 용해에 의해 생성되고 일부는 조류 등의 광합성에 의해 생성됩니다. DO 농도가 너무 낮아지면 호흡 곤란, 수역, 수생 동물의 활동 감소 및 치명적일 수 있습니다. 자연에서 DO의 농도 범위는 8-10ppm입니다. 이것은 온도와 화학적 분해 및 기타 요인에 따라 변동합니다. DO는 또한 성장하는 산업에서 수질 오염을 증가시키는 중요한 지표입니다. 수질 측정에서 pH는 물의 산성/염기성 정도를 나타냅니다. 범위는 0에서 14까지이며, 7은 중성, 7 미만은 산성, 7 초과는 염기성을 나타냅니다. 염도는 물에 녹아 있는 염분의 양을 측정한 것입니다.

건강에 좋지 않거나 토종 식물이 죽어 있는 물의 높은 염도는 내염성 종의 우세를 통해 생태계 구조를 변경할 가능성이 있습니다. 베리에이션가 많은 NTU(신탁도 단위)는 수질의 중요한 매개변수입니다. 빛의 산란이 클수록 불

투명도가 높아집니다. 탁도 값 허용은 높은 물 투명도를 나타냅니다. 높은 값은 낮은 물 투명도를 나타냅니다. 또한 현미경의 수를 세는 컴퓨터 비전 기술을 기반으로 세포 탐지를 적용했습니다. 이 값은 이 연구에서 대상 레이블로 간주되었습니다.

이 데이터 세트를 조사하는 동안 시간 경과에 따른 측정값의 변화인 현미경의 분포를 분석했습니다. 또한 측정값과 현미경 수와의 상관관계도 분석합니다(그림 2). 가용한 분석에 따르면 고성에서는 데이터가 풍부하고 더 잘 분포되어 있는 반면 일해에서는 훈련용으로 사용하기가 더 어려운 것으로 보입니다. 따라서 우리는 훈련 진행을 위해 고성 데이터를 사용하고, 일해 데이터를 테스트 세트로 간주하기로 결정했습니다.

#### 나. 제안 방법

1) 개요: 이 프로젝트에서 저희는 전통적인 머신 러닝과 딥 러닝 모델을 기반으로 수질을 제어하기 위해 데이터 센서에서 물의 현미경 및 세포 수를 예측하는 시스템을 제안했습니다. 인공 지능(AI)의 발전은 머신러닝과 딥 러닝의 원리를 실제 응용 프로그램에 통합하는 것을 촉진했습니다. 이러한 조건을 바탕으로 복잡한 측정 및 계산 프로세스와 외부 요인에 쉽게 영향을 받을 수 있는 프로그램을 교체 가능한 스마트 프로그램을 설계하는 것을 목표로 합니다. 물 샘플에 대한 수산양식업 측정 지표(pH, 염도, NTU, DO, 온도)를 통해서 샘플의 세포 수를 예측합니다. 이를 통해 저희는 최소한의 노력과 시간으로 수산양식장에서 사료 공급량을 제어할 수 있습니다. 머신러닝 기술은 최신 고성능 컴퓨터 및 하드웨어 장치와 협력하여 데이터의 다차원 기능과 깊이 정보를 활용할 수 있습니다.

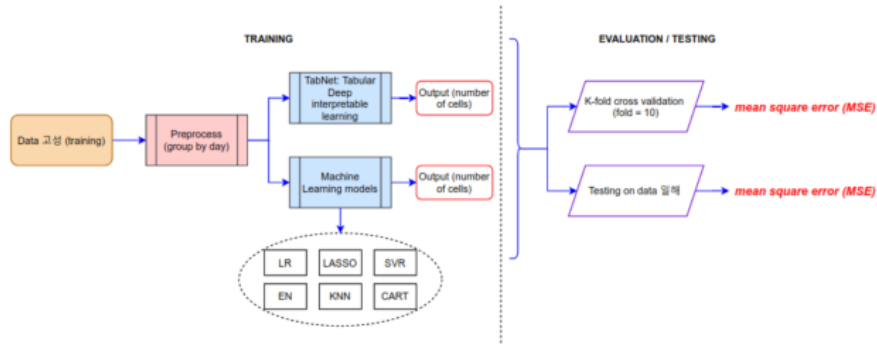


Fig. 3: The overall framework for number microscopy prediction.




Fig. 4: TabNet model implemented on the system.

전반적으로 이 문제를 지도 학습 문제로 틀 수 있습니다. 여기서 저희는 다양한 회귀 모델을 사용하여 제공된 양식 측정 지수 내의 관계를 학습하고 수중 현미경 밑 총 세포 수를 예측했습니다.

2) 모델 아키텍처: 이 작업에 대한 전체 연구 파이프라인은 그림 3에 설명되어 있습니다. 위에서 언급한 바와 같이 우리의 관찰을 기반으로 고성 지역의 데이터는 풍부하고 균형 잡히고 덜 시끄럽기 때문에 훈련은 이 세트에 진행을 수행했습니다. 회귀 모델에 데이터를 제공하기 전에 샘플을 일별로 그룹화합니다. 각 날짜의 측정 지표 값은 해당 날짜의 모든 측정 시간의 평균으로 계산됩니다. 모델의 경우 선형 회귀분석(LN), 올가미 회귀분석(LASSO), 서포트 벡터 머신(SVR), 엘라스틱넷 회귀분석(EN), K-최근접 이웃 과 분류 및 회귀 트리를 포함한 회귀 문제의 6가지 고전적인 알고리즘을 사용했습니다. 게다가 저희는 동일한 작업에 대한 테이블 형식 학습을 위한 주의 트랜스포머를 기반으로 하는 새로운 딥 러닝 방법인 TabNet을

적용했습니다.

#### 다. TabNet 모델




Fig. 5: TabNet architect.

TabNet[9]은 종단 간 학습 프로세스에 유연하게 통합할 수 있도록 경사하강법을 기반으로 훈련되었습니다. 가장 유용한 기능에 학습 용량이 사용되므로 더 나은 해석과 학습을 위해 각 결정 단계에서 인스턴스별 기능 선택에 시퀀스 주의가 적용됩니다. 또한 단일 딥 러닝 엔진을 특징 선택 및 추론에 활용합니다. Tabnet의 아키텍처는 그림 5에 나와 있습니다. 데이터에 대한 TabNet 모델 구현의 세부 사항은 그림 4와 같습니다. 모델의 인코더 단계는 기능 트랜스포머, 기능 마스킹 및 주의 변환기

TABLE I: Comparison between the proposed method (TabNet) with baseline machine learning models

Method	Goseong		Ilhae	
	MAPE	MSE	MAPE	MSE
Linear Regression (LR)	0.591	4625	1.243	8232
Lasso Regresson (LASSO)	0.599	4402	1.242	8150
Elastic-Net regression (EN)	0.586	3850	1.141	7323
K Nearest Neighbour (KNN)	0.554	3601	1.010	8281
Classification and Regression Trees (CART)	0.520	4816	1.118	10788
Super vector regression (SVR)	0.629	4417	0.822	6916
Our method using TabNet	<b>0.278</b>	<b>1057</b>	<b>0.397</b>	<b>2834</b>

로 구성됩니다. 모델의 해석 가능한 정보가 포함된 기능 선택 마스크는 중요한 기능을 캡처하기 위해 연결됩니다. 인코더 단계에서는 특징 재구성을 위해 각 단계에서 특징 트랜스포머 블록이 사용됩니다.

### III. 실험 결과

평가 과정에서 과적합 문제를 방지하는 효과적인 기술인 K-fold 검증을 사용합니다. 얻은 결과에서 훈련 세트와 테스트 세트 모두에 대한 K-겹 검증 결과가 나옵니다. 본 연구의 모든 방법에 사용된 평가 지표는 평균 제곱 오차 (MSE)이며,

다음과 같이 계산:

$$MSE = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2$$

여기서 N은 테스트 샘플의 수,  $y_i$ 는 실제예측값,  $\hat{y}_i$ 는 관측값입니다. 오류 값이 낮을수록 모델의 성능이 더 좋습니다. 게다가, 저희는 또한 평균 절대 백분율 오차(MAPE)를 사용했습니다.

다음과 같이 계산:

$$MAPE = \frac{100\%}{N} \sum_{i=1}^N \left| \frac{\hat{y}_i - y_i}{\hat{y}_i} \right|$$

이 비율의 절대값은 모든 예측 시점에 대해 합산하여 적합점 수 N으로 나눈 값이다. 실험 결

과는 표 1에 나타내었다. 위의 결과는 고성 지역이 더 나은 데이터 품질로 인해 지역보다 전반적인 방법의 성능이 우수함을 보여줍니다. TabNet 모델은 다른 머신 러닝 기반 방법에 비해 성능이 뛰어납니다. 고성 세트에서 MAPE 0.287, MSE 1057을 얻었습니다. 따라서 기계 모델 중 최고(0.520 MAPE의 CART 0.520 과MSE의 KNN 3601)와 비교하여 상당한 개선을 보여줬습니다. 일해에서도 저희의 방법은 MAPE가 0.367, MSE가 2834로 가장 좋은 결과를 얻었습니다. 트리 기반과 해석 가능한 학습의 조합은 훈련 프로세스의 견고성 기능을 활용했습니다는 것을 보일 수 있습니다.

### IV. 결론

이 논문에서 우리는 수질 제어를 위한 데이터 센서로부터 먹이생물의 품질 예측을 위해 구현된 새로운 딥 러닝 방법을 제안했습니다. 주의 테이블 형식 학습 접근 방식의 적용은 전체 벤치마크 기존 기계 학습 시스템의 잠재적 개선을 보여줍니다. 그러나 저희 시스템은 과거의 해석 소스를 활용하여 미래 결과를 예측하는 시간적 컨텍스트 정보를 기반으로 계속 발전할 수 있습니다. 이를 바탕으로 다른 딥 러닝 모델을 구현하여 시스템을 확장하고 시계열 기반에 따라 시스템을 개발하는 것이 향후 목표입니다.

## REFERENCES

- [1] X. Su, L. Sutarlie, and X. J. Loh, "Sensors, Biosensors, and Analytical Technologies for Aquaculture Water Quality," Research, vol. 2020, pp. 1–15, 2020.
- [2] K. Lorenzen, I. G. Cowx, R. M. Entsua-Mensah, N. P. Lester, J. D. Koehn, R. G. Randall, N. So, S. A. Bonar, D. B. Bunnell, P. A. Venturelli, S. D. Bower, and S. J. Cooke, "Stock assessment in inland fisheries: a foundation for sustainable use and conservation," Reviews in Fish Biology and Fisheries, vol. 26, pp. 405–440, 2016.
- [3] G. G. Monkman, K. Hyder, M. J. Kaiser, and F. P. Vidal, "Using machine vision to estimate fish length from images using regional convolutional neural networks," Methods in Ecology and Evolution, vol. 10, no. 12, pp. 2045–2056, 2019.
- [4] F. Fernandes, E. M. Turra, E. R. de Alvarenga, T. L. Passafaro, F. B. Lopes, G. F. Alves, V. Singh, and G. J. Rosa, "Deep Learning image segmentation for extraction of fish body measurements and prediction of body weight and carcass traits in Nile tilapia," Computers and Electronics in Agriculture, vol. 170, no. June 2019, p. 105274, 2020. [Online]. Available: <https://doi.org/10.1016/j.compag.2020.105274>
- [5] Zion, "The use of computer vision technologies in aquaculture - A review," Computers and Electronics in Agriculture, vol. 88, pp. 125–132, 2012. [Online]. Available: <http://dx.doi.org/10.1016/j.compag.2012.07.010>
- [6] S. Kim, M. Alizamir, M. Zounemat-Kermani, O. Kisi, and V. P. Singh, "Assessing the biochemical oxygen demand using neural networks and ensemble tree approaches in South Korea," Journal of Environmental Management, vol. 270, no. May, p. 110834, 2020. [Online]. Available: <https://doi.org/10.1016/j.jenvman.2020.110834>
- [7] Y. F. Zhang, P. Fitch, and P. J. Thorburn, "Predicting the trend of dissolvedn oxygen based on the kPCA-RNN model," Water (Switzerland), vol. 12, no. 2, pp. 1–15, 2020.
- [8] J. Huan, H. Li, M. Li, and B. Chen, "Prediction of dissolved oxygen in aquaculture based on gradient boosting decision tree and long short-term memory network: A study of Chang Zhou fishery demonstration base, China," Computers and Electronics in Agriculture, vol. 175, no. May, p. 105530, 2020. [Online]. Available: <https://doi.org/10.1016/j.compag.2020.105530>
- [9] S. O. Arik and T. Pfister, "TabNet: Attentive Interpretable Tabular Learning," 2019. [Online]. Available: <http://arxiv.org/abs/1908.0744>